

# Nyílt forráskódú elosztott rendszerek

Trencsényi Márton, [mtrencseni@scalien.com](mailto:mtrencseni@scalien.com)

Gazsó Attila, [agazso@scalien.com](mailto:agazso@scalien.com)

## Kivonat

Az előadás tézise, hogy néhány éven belül nyílt forrású elosztott rendszerek fognak nagy skálájú, nagy megbízhatóságú webes háttérarchitektúrát szolgáltatni. Ezen rendszerek jelenleg a nagy Internetes cégek, mint Google, Amazon és Facebook által nyilvánosságra hozott architektúrák, mérnöki tapasztalatok, illetve forráskódok alapján készülnek. Az előadásban ismertetjük az iparág által felhalmozott tapasztalatokat és tervezési pontokat, melyek segítségével jobban átláthatóak az elosztott rendszerek közötti különbségek, előnyök, hátrányok. Az előadás második felében a jelenleg is elérhető elosztott rendszereket ismertetjük, különös hangsúlyt fektetve a saját készítésű Keyspace kulcs-érték adatbázisunkra.

## 1. Bevezetés

Ma már a legtöbb alkalmazás *web alkalmazás*, melyek az Interneten vagy belső hálózatokon futnak. A web alapú alkalmazások sajátossága, hogy a felhasználó adatait a szolgáltató rendszerein tárolják, és az alkalmazás futása során a szolgáltató rendszere is számításokat végez. A webes alkalmazások természetüknél fogva elosztott rendszerek, általában három különböző számítógépen fut a browser, az alkalmazás szerver és az adatbázis szerver. Egyre inkább igény van arra, hogy ezek az elosztott rendszerek, pontosabban az alkalmazás és adatbázis réteg skálázhatók és/vagy hibatűrők legyenek, azaz minél több klienst ki tudjanak szolgálni, minél több adatot tudjanak tárolni, illetve egyes komponensek meghibásodása esetén a rendszer összességében tovább üzemeljen.

Az előadásban bemutatandó *nyílt forráskódú* elosztott rendszereket néhány éve kezdték el fejleszteni, de egy-két kivételtől eltekintve de facto standard megoldások (mint pl. Mysql nyílt forrású adatbázisok terén) még nincsenek. Az előadás alaptézise, hogy néhány éven belül létezni fognak produkciós rendszerekben használható skálázható, hibatűrő nyílt forráskódú rendszerek; az előadás ezeknek a rendszereknek a rövid történetével kezdődik, majd néhány, már használható rendszert mutat be, különös hangsúlyt fektetve a szerzők saját (Scalien Kft.) készítésű nagy megbízhatóságú kulcs-érték adatbázisára, a *Keyspace*-re.

Az előadás első részében általános elveket ismertetek melyek az elosztott rendszerek megértéséhez elengedhetetlenek: shared nothing architektúra, CAP háromszög, konzisztencia kérdések.

A legelső, nagyon nagy webes alkalmazásokat kiszolgáló elosztott rendszerek nagy Internetes cégeknél alakultak ki. Néhány rendszernek cikkekben publikálták a rendszer működését, néhány rendszernek pedig kiadták a forráskódját is. A jelenleg fejlesztés alatt álló nyílt forráskódú projektek is ezen — komoly mérnöki tudást és tapasztalatokat képviselő — rendszerekből merítenek ötleteket és általános elveket, gyakran ezeket a rendszereket duplikálják. Ezért az előadás első részében a *Google*

*Chubby, GFS, MapReduce, BigTable és az Amazon Dynamo* belső használatban lévő elosztott rendszereit ismertetem a fontosabb tervezési pontokra koncentrálni.

Az előadás második részében 1.x verzióját tartó, jelenleg is fejlesztés alatt álló, saját fejlesztésű *Keyspace* rendszert mutatom be, majd röviden összefoglalom az *Apache Hadoop* és a *Facebook Cassandra* projekteket.


## 2. Elosztott rendszerek alapelvei

A webes alkalmazások és az open-source világában az ún. *shared nothing* [1] elosztott architektúra dominál, ami lényegében azt jelenti, hogy a különálló szerverek együttesen alkotnak egy elosztott rendszert, de nincsen szorosan csatolva (pl. hardveres vagy operációs rendszer szinten) a gépek memóriája (shared memory) vagy diskei (shared disk).

Az elosztott rendszereknél alapvető ökölszabály az ún. *CAP* (*consistency, availability, partition tolerance*) tézis [2], mely azt mondja ki, hogy a felsorolt három tulajdonság közül nem valósítható meg mindegyik (egyszerre *shared nothing* architektúrákban). A három fogalom tömör magyarázata:

1. *Konzisztencia*: ez elosztott rendszerhez intézett egymást követő írás és olvasás műveletek esetén — melyeket potenciálisan más-más szerver szolgál ki — milyen garanciákat nyújt a rendszer arra, hogy az olvasás során az előzőleg beírt adatot vizsgáljuk.
2. *Rendelkezésre állás*: a rendszer képes kérések (írás és olvasás műveletek) kiszolgálására néhány szerver kiesése mellett is.
3. *Partíció tolerancia*: a rendszer hibatűrése, amennyiben a szervereket összekötő hálózat (hub, switch, router, kábel) meghibásodása esetén a rendszer kettő vagy több különálló hálózatra esik szét.

Két rövid példán keresztül ecseteljük, hogy a „CAP háromszögben” elhelyezett különböző rendszerek hogyan viselkedhetnek.



1. ábra. A CAP háromszög.

Első példaként képzeljünk el egy  $n = 3$  szerverből álló rendszert, ahol induláskor mindhárom szerver szerint az *mtrencseni* felhasználó (az elosztott adatbázisban) tárolt születési dátuma 1881-04-24, majd átjavítjuk 1981-04-24-re, de a változás csak az 1. és 2. szerveren történik meg, és azok, mielőtt továbbítanák a változást a harmadikhoz, hiba folytán lekapcsolódnak. Újra lekérdezve a születési dátumot a még rendelkezésre álló szervertől a régi, elavult, „rossz” adatot kapjuk vissza. Egy ilyen esetet engedélyező rendszert *gyengén konzisztensnek* nevezünk. Ez a furcsa, de nagy arányban rendelkezésre álló és mindenféle particionálást magában foglaló működés előnyös, amikor egy „rég, elavult, kicsit rossz” adat visszanyerése

előnyösebb, mint hibával visszatérni. Ilyen, gyengén konzisztens rendszer például a később bemutatott Amazon Dynamo.

Második példaként vegyünk egy „többség alapú” rendszert, amelynél írás és olvasás műveletekhez a szerverek többsége rendelkezésre kell hogy álljon. Egy ilyen rendszer csak akkor nyugtázza az írás műveletet, ha a szerverek többségén az adat kikerült a diszkre. A fenti  $n = 3$  példánál maradva, egy írás műveletet akkor nyugtáz a rendszer, ha legalább két szerverre kikerült az új 1981-04-24 adat. Amennyiben két szerver kiesik, a rendszer nem tudja az olvasás műveletet kiszolgálni, mert ahhoz a szerverek többsége kell; viszont ha kettő rendelkezésre áll, akkor mindig vissza tudja adni a „jó, friss” értéket, hiszen az a rendelkezésre álló két gépből legalább az egyiken megtalálható. Az ilyen, erősebb garanciát biztosító rendszereket *erősen konzisztensnek* nevezzük. Ilyen rendszerekben a működéshez többség kell, egészséges állapotában nagyon hasonlít egy hagyományos, egyszerveres rendszerre. Az erős konzisztencia ára, hogy a szerverek többsége egy partícióban rendelkezésre kell hogy álljon. Ilyen, erősen konzisztens rendszer például a Key-space.

### 3. A Google architektúrája

A Google néhány évvel ezelőtti cikkek formájában nyilvánosságra hozta belső rendszerének leírását. A rendszert a Google keresőjére optimalizálták, azóta azonban teljesen más alkalmazások is futnak fölötté, pl. Google Mail és Google App Engine, ami az eredeti rendszer robosztus jellegét jelzi.

A Google architektúrája a következő elemekből épül fel:

1. Chubby: elosztott lock szerver [4].
2. Google File System (GFS): nagy teljesítményű elosztott file rendszer [5].
3. MapReduce: elosztott batch feldolgozó rendszer [6].
4. Bigtable: tábla alapú elosztott adatbázis [7].

A *Chubby* egy elosztott lock szerver, amelyet más szolgáltatások (pl. GFS vagy Bigtable) használnak jól ismert elosztott primitívként. Egy Chubby cella több tízezer másik szerveren futó elosztott rendszert szolgál ki, amelyek master választásra és konfigurációs metaadatok (pl. mely szerverek részei a rendszernek) megosztására használják a cellát. A Chubby egy erősen konzisztens rendszer, lényegében a többségi alapú Paxos [3] algoritmust valósítja meg, melyről később még lesz szó a Keyspace kapcsán.

A *Google File System (GFS)* a Google nagy teljesítményű elosztott filerendszere, melyet a keresőhöz szükséges nagy mennyiségű, szekvenciális íráshoz (pl. weboldalak lementése), és kevesebb, véletlenszerű olvasáshoz (pl. keresésnél) optimalizáltak. Master-alapú filerendszer, ahol a master tárolja az összes metaadatot, és ún. chunkszerverek tárolják a chunkokra bontott fileokat 64MB-os blokkokban, replikálva. Érdekesség, hogy a master szerver az összes metaadatot memóriában tárolja, hogy a kliens kéréseket megfelelő sebességgel kiszolgálhassa, ami bizonyos korlátokat jelent a rendszerre nézve (metaadat mérete). Egy GFS rendszer néhány millió filet, petabyte mennyiségű adatot tárol. A metaadatok erősen konzisztensek, mivel a master szerveren keresztül történik a változtatásuk, míg az chunkok egyfajta „eventual consistency” („előbb-utóbb konzisztens lesz”) modellt követnek, melyre az elosztott filerendszert használó alkalmazásnak fel kell készülnie.

Míg az eddig felsorolt rendszerek file vagy adatbázis rendszerek voltak, a *MapReduce* egy elosztott job-kezelő rendszer, melyet a Google a keresője alapjául szolgáló

invertált index előállításához használ. A MapReduce lényege, hogy a feladatot a funkcionális nyelvekből ismert Map és Reduce lépésekre bontja, amelyeket a rendszer automatikusan szétoszt és két fázisban végrehajta őket. A legegyszerűbb példa, ahogy weblapokban szavak előfordulását számolja ki: a Map lépésben egy weblapból kiszedi a  $w$  szavakat, és  $(w, \text{darab})$  alakú kulcs-érték párokat ír ki; a Reduce lépésben a  $w$  szót tartalmazó párokban található darabszámokat összeadja, így megkapjuk a szavak előfordulását egy adott mintában. A Map és Reduce lépések eloszthatóak, így nagy mennyiségű adatot lehet egyszerre, gyorsan feldolgozni. A Google esetében a MapReduce rendszer GFS vagy Bigtable fölött fut.

Az utolsó itt említett Google rendszer a tábla (igazából sor/oszlop) alapú Bigtable. A hagyományos relációs adatmodell helyett a Bigtable egy elosztott módon is implementálható, lényegében kulcs-érték adatmodellt kínál. A Bigtable adatokat (sor, oszlop)  $\rightarrow$  adat címmel kaphatja vissza a kliens, illetve egy plusz verziót is megadhat, amivel egy bizonyos adat régebbi verzióját kaphatja vissza, mert a Bigtable változtatás esetén automatikusan tárolja a régi verziókat is. A hozzáférés sor (és oszlop) szinten történik, és csak sor szintű módosítások végezhetők tranzakción. A Bigtable GFS fölött fut, és Chubby-t használ master kiválasztásra és metaadat tárolására.

## 4. Amazon Dynamo

Az Amazon több belső elosztott rendszert is üzemeltet: egy részük az `amazon.com` online boltot szolgálja ki, egy másik részük az Amazon Web Services (AWS) rendszert alkotják. Itt az online boltnál használt Dynamo rendszert mutatjuk be röviden egy 2007-ben kiadott cikk alapján [8].

A Dynamo egy gyengén konzisztens rendszer, melynek a célja, hogy minden esetben kiszolgálja a kliens kéréseit — akkor is, ha nem tud teljesen friss adattal szolgálni valamilyen hiba miatt. Ezt az online bolt követeli meg, melynek mindig működnie kell („always-on experience”), ugyanis ha nem működik, akkor jól becsülhető, lényeges pénzügyi veszteséget szenved a cég. A rendszer kulcs-érték alapon működik, a kulcs-érték párok többszörösen replikálva vannak. A gyenge konzisztencia miatt ugyanazon adat több verziója is jelen lehet a rendszerben, ezért az adatokat a rendszer családfaszerűen verzióbélyegekkel látja el. Amennyiben egy adatnak több verziója van jelen, azt előbb-utóbb észleli a rendszer, és egy alkalmazás-specifikus konfliktus feloldó algoritmus újra előállítja egy konzisztens elosztott állapotot. Ezért ezt a modellt *eventual consistency*-nek is hívják („előbb-utóbb konzisztens lesz”).

Például, tegyük fel hogy az `mtrencseni` vásárlónak két könyv van a kosarában, A és B. A vásárlás folyamata közben a felhasználó kosarát tároló szerverek hálózati hiba miatt lekapcsolódnak, ezért a rendszer nem éri el a kosár legutolsó állapotát, így a rendszer a kosarat üresnek jelzi a felhasználónak. A felhasználó érzékeli a hibát, és újra beletakja az A és B könyvet, majd kicsit később egy új C könyvet. Közben a hálózati hiba helyreáll, és a rendszer érzékeli, hogy a felhasználónak két különböző verziójú kosara van a rendszerben. Ilyenkor egy konfliktust feloldó (kosár)alkalmazás specifikus algoritmus előállít egy új, konzisztens állapotot, pl. a kosarak unióját képz.

## 5. Scalien Keyspace

A saját készítésű, kulcs-érték alapú *Keyspace adatbázis* az első nyílt forráskódú rendszer melyet bemutatunk. A Keyspace az eddig bemutatott rendszerek közül leginkább a Google Chubby rendszeréhez hasonlít. A Keyspace egy konzisztensen replikált adatbázis: replikált, mert az összes szerver ugyanazt az adatot tárolja; konzisztens, mert a CAP háromszögben a konzisztenciára helyezi a hangsúlyt (vs. „eventual consistency”), és garantálja, hogy sikeres írások után az olvasások tükrözik az írást, akármilyen hálózati vagy szerver hiba esetén is.

Hasonlóan a Chubby-hoz a Keyspace is a Paxos elosztott konszenzus algoritmust valósítja meg (mely egy többségi algoritmus). A Keyspace cellákat  $n = 3$  konfigurációban futtatva, pl. egy szerver 95%-os rendelkezésre állása 99.27%-ra javítható (ld. táblázat).

szerverek	többség	rendelkezésre állás
1	1	95.00%
2	2	90.25%
<b>3</b>	<b>2</b>	<b>99.27%</b>
4	3	98.59%
5	3	99.88%
..	..	..

1. táblázat. Rendelkezésre állás különböző méretű Keyspace cellák esetében.

A rendszer lelkét alkotó elosztott algoritmus, a Paxos miatt a Keyspace minden praktikus esetben előálló hálózati vagy szerver hiba esetet kezel, és tovább üzemel, amennyiben a szerverek többsége rendelkezésre áll és kommunikál:

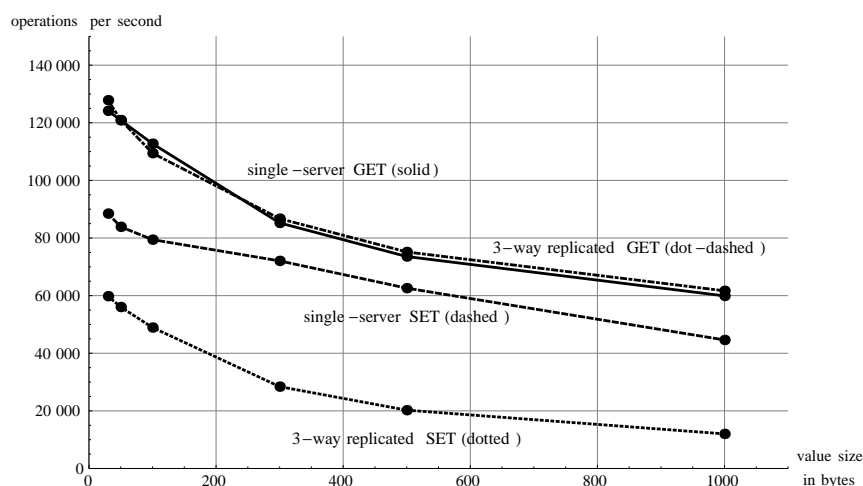
1. Szerverek leállnak és újraindulnak: a Keyspace programot futtató szerverek leállhatnak és újraindulhatnak, elveszítve a memóriában tárolt állapotot, de nem a diszkre kiírt adatokat.
2. Hálózati partíciók: hubok és routerek tönkremehetnek, ezért a hálózat átmenetileg részekre eshet.
3. Csomagvesztés, duplikáció és átrendeződés: operációs rendszerek hálózati stackje és routerek eldobhatnak és átrendezhetnek üzeneteket. A TCP-szerű protokollok garantálják ezen esetek kezelését, míg az UDP-szerűek nem. A Keyspace mindkét fajta hálózati protokoll fölött tud futni.
4. Hálózati késleltetések: terhelt helyi hálózatokon és WAN-okon (Internet) az üzenetek több másodperces késéssel érkezhetnek meg a címzetthez. A Keyspace minden esetben erős konzisztenciát nyújt.

A Keyspace más kulcs-érték adatbázisokhoz képest viszonylag kiterjedt adat-hozzáférési API-val rendelkezik (ld. alább). Az olvasási műveleteknek létezik piszkos („dirty”) verziója is, mely semmilyen konzisztencia garanciát nem ad, viszont akár egyedülálló szerver is ki tudja szolgálni. A támogatott műveletek:

- **GET(key)**: visszaadja a **key**-hez tartozó értéket, ha létezik az adatbázisban.
- **SET(key, value)**: beállítja a **key** értékét, átírva az előző értéket ha létezett az adatbázisban.

- **TEST-AND-SET(key, test, value)**: atomi módon átírja **key** értékét **value**-ra, ha a jelenlegi értéke **test**.
- **ADD(key, a)**: a **key** értéket számként értelmezi és hozzáad **a**-t.
- **RENAME(key, newKey)**: átnevezi **key**-t **newKey**-re, megtartva az értékét.
- **DELETE(key)**: kitörli **key**-t és az értékét az adatbázisból.
- **REMOVE(key)**: kitörli **key**-t és az értékét az adatbázisból, visszaadja az értéket.
- **PRUNE(prefix)**: kitörli az összes kulcs-érték párt amely **prefix**-szel kezdődik.
- **LIST-KEYS(prefix, startKey, count, next, forward)**: legfeljebb **count** kulcsot ad vissza, melyek **prefix**-szel kezdődnek, a **startKey** kulcstól indulva. Amennyiben a **startKey** kulcs nem létezik az adatbázisban, ABC-szerint a következő kulcsnál kezdődik. Amennyiben **startKey** létezik, átugorható **next = true** beadásával. Ez webes „lapozott” oldalak előállításánál hasznos.
- **LIST-KEYVALUES(prefix, startKey, count, next, forward)**: ugyanaz, mint **LIST-KEYS**, de a kulcsokon kívül az értékeket is visszaadja.
- **COUNT(prefix, startKey, count, next, forward, forward)**: visszaadja a kulcsok számát, melyeket az ugyanezen paraméterekkel meghívott **LIST** adna vissza.
- **DIRTY-GET(key)**: mint az előző **GET**, de konzisztencia garanciák nélkül.
- **DIRTY-LIST-KEYS(prefix, startKey, count, next, forward)**: mint az előző **LIST-KEYS**, de konzisztencia garanciák nélkül.
- **DIRTY-LIST-KEYVALUES(prefix, startKey, count, next, forward)**: mint az előző **LIST-KEYVALUES**, de konzisztencia garanciák nélkül.
- **DIRTY-COUNT(prefix, startKey, count, next, forward)**: mint az előző **COUNT**, de konzisztencia garanciák nélkül.

A Keyspace adatbázist saját, nagy hatékonyságú protokollon ill. adminisztrációs és tesztelési célokból HTTP illetve HTTP+JSON API-n keresztül lehet elérni. A nagyhatékonyságú aszinkron architektúra miatt a Keyspace nagyszámú konkurens műveletet ki tud szolgálni (ld. köv. ábra).



2. ábra. Keyspace bulk adatátviteli sebességek.

A Keyspace letölthető a Scalien honlapjáról a <http://scalien.com> címen, az adatbázis és kliens library-k (C, PHP, Python) a nyílt BSD licenz alatt érhetők el.

## 6. Más nyílt forráskódú elosztott rendszerek

Alább a teljesség igénye nélkül felsoroljuk a fontosabb nyílt forráskódú elosztott rendszereket, rövid leírással.

1. *Apache Hadoop*. Az Apache Foundation Java alapú projektje, mely az ismert Google architektúrát másolja. A *HDFS* a GFS, a *HBase* a Bigtable megfelelője, illetve tartalmaz *MapReduce* modult is. A Hadoop-ot eredetileg a Yahoo! cég fejlesztette ki, egyben a legnagyobb felhasználója is, és hasonló feladatokra használja, mint a Google saját rendszerét. A Hadoop rendszer viszonylag elterjedt és népszerű, pl. AWS-en „natív” módon lehet futtatni.
2. *Facebook Cassandra*. A Cassandra a Facebook Java alapú belső projektje, melyet az Amazon Dynamo egyik eredeti fejlesztője vezet, így sokban hasonlít ahhoz. A hangsúly a véletlen műveletek (vs. bulk írások vagy olvasások) kiszolgálásán van, könnyen skálázható, a Dynamohoz hasonlóan gyengén konzisztens („eventual consistency”). Az adatmodellt a Bigtable-től kölcsönzi: táblaszerű, de gyakorlatilag kulcs-érték alapú.
3. *Memcached*. A Memcached-t a Danga Interactive cégnél fejlesztették ki a LiveJournal szolgáltatásukhoz. A Memcached önmagában nem egy elosztott rendszer, csupán egy tisztán memóriában dolgozó, kulcs-érték alapú *cache*. A cachelés azonban annyira alapvető része egy nagy teljesítményű elosztott rendszernek, hogy ezt a viszonylag egyszerű szoftvert használják a leggyakrabban (pl. Facebook rendszereiben is). Mivel a Memached maga nem tud a többi szerveren futó másik Memcached példányokról, ezért az alkalmazás feladata a kulcsok szétosztása és nyilvántartása. Egy jól működő rendszerben a kérések nagy hányadát (pl. több mint 95%) kívánatos cache-ből kiszolgáltatni, diszk hozzáférés nélkül.

## 7. Konklúzió

A webes alkalmazások és hálózatba kapcsolt eszközök terjedésével egyre több adattárolási- és számítási kapacitásra van szükség a szolgáltatók oldalán, akiknek üzleti igényük, hogy szolgáltatásaik gyorsak, megbízhatóak és skálázhatóak legyenek. A szolgáltatók egy jelentős része kulturális és anyagi okokból kifolyólag nyílt forráskódú megoldásokat alkalmaz az adattárolási- és feldolgozási feladatokra. Az előadás során megmutattuk, hogy a nagy Internetes cégek milyen belső megoldásokat használnak, azok milyen tulajdonsággal rendelkeznek és ennek milyen következményei vannak (pl. konzisztencia). Végül bemutattunk néhány jelenleg is elérhető nyílt forráskódú elosztott rendszert, melyek a „nagyok” rendszerei alapján készülnek. Tézisünk szerint ezekből vagy hasonló rendszerekből fog kialakulni néhány éven belül egy *nyílt forráskódú elosztott stack*.

## Hivatkozások

- [1] M. Stonebraker. *The Case for Shared Nothing*, Database Engineering, Volume 9, Number 1 (1986).
- [2] E. Brewer. *Keynote Address*, Symposium on Principles of Distributed Computing (2000).
- [3] L. Lamport, *Paxos Made Simple*, ACM SIGACT News 32, 4 (Dec. 2001), pp. 18-25.

- [4] M. Burrows, *The Chubby Lock Service for Loosely-Coupled Distributed Systems*, OSDI '06: Seventh Symposium on Operating System Design and Implementation.
- [5] S. Ghemawat, H. Gobioff, S. Leung, *The Google File System*, 19th ACM Symposium on Operating Systems Principles (2003).
- [6] J. Dean, S. Ghemawat, *MapReduce: Simplified Data Processing on Large Clusters*, OSDI'04: Sixth Symposium on Operating System Design and Implementation (2004).
- [7] F. Chang et al., *Bigtable: A Distributed Storage System for Structured Data*, OSDI'06: Seventh Symposium on Operating System Design and Implementation (2006).
- [8] W. Vogels et al., *Dynamo: Amazon's Highly Available Key-value store*, SOSP '07: Proceedings of twenty-first ACM SIGOPS symposium on Operating systems principles (2007), pp. 205-220.
- [9] M. Trencseni, A. Gazso, *Keyspace: A Consistently Replicated, Highly-Available Key-Value Store*, <http://scalien.com/whitepapers>.